




- ◆ 데이터 전처리과정 알기
- 데이터 전처리하기(실습)




- 데이터 전처리과정의 필요성에 대해 설명할 수 있다.
- ◆ 데이터 전처리 작업을 수행할 수 있다.









# What's the least enjoyable part of data science?

- Building training sets: 10%
- Cleaning and organizing data: 57%
- Collecting data sets: 21%
- Mining data for patterns: 3%
- Refining algorithms: 4%
- Other: 5%

● 데이터 나누기

학습 데이터 세트(Training Dataset)

◆ 머신러닝 인풋

테스트 데이터 세트(Test Dataset)

◆ 모델의 성과 측정

### 데이터 나누기

### 선형 표본화(linear sampling)

◆ 데이터를 순차적으로 선별


### 무작위 표본화(random sampling)

◆ 무작위로 랜덤하게 분류


### 증화 표본화(stratified sampling)

◆ 각각의 레이블별로 무작위 추출


- → 값이 없는 경우: 결측치(Missing value)
  - ◆ 속성 사용 여부
  - ◆ 해당 사례만 제거
  - ◆ 결측치 예측




필요한 데이터 가져오기


















## CAU


#### 2. 데이터 전처리하기(실습)



trim을 가져온 후 read excel 옆에 드래그 및 연결








### CAU


#### 2. 데이터 전처리하기(실습)



add filter → is not missing 선택




#### 2. 데이터 전처리하기(실습)



remove duplicate 오퍼레이터 사용하여 중복 데이터 없애기




#### 2. 데이터 전처리하기(실습)




파라미터 설정으로 single 선택 후 중복되는 데이터 없애기


### CAU




### CAU








### CAU






#### 2. 데이터 전처리하기(실습)




churn 데이터를 선택해서 속성 자체를 데이터에서 없앰






### CAU

#### 2. 데이터 전처리하기(실습)




묶고자 하는 서브프로세스를 선택 → 우클릭 → move into new sub-process 클릭



### CAU

#### 2. 데이터 전처리하기(실습)



set role 오퍼레이터를 사용하여 레이블로 지정